Pontificia Universidad Javeriana · Especialización en Inteligencia Artificial

Proyecto de Aplicación en IA · Ciclo 2

BolsaLAB

Ciclo 2: preparación de los datos (sprints 3 y 4)

Grupo 10

Jenny Paola Castellanos

Luis Guillermo Yépez

Dilan Vega

Juan Gilberto Ayala

19 de octubre de 2026

1. Resumen

BolsaLAB es un copiloto educativo para personas colombianas que quieren empezar a invertir. Este documento reúne los resultados del ciclo 2 de CRISP-DM: los sprints 3 y 4, dedicados a preparar los datos con los que se entrenarán los primeros modelos.

- *Objetivo redefinido.* Con el estado del arte (47 documentos y 11 datasets revisados), el modelo dejó de clasificar el perfil de riesgo y ahora predice si una persona con inversiones vende todo o parte, o mantiene, durante una caída del mercado.
- *Datos de entrenamiento listos.* Encuesta japonesa de la caída de marzo de 2020 (Bawalle et al., 2025): 54.704 inversionistas, de los cuales vendió el 19,87 %. Hay 17 variables de entrada, una por pregunta de la app, sin columnas que revelen la respuesta. La tabla sale de código reproducible y la verifican 23 pruebas automáticas.
- *Contraste fuera de Japón.* El panel SCF 2007-2009 de EE. UU. quedó preparado: 1.563 familias con acciones o fondos antes de la crisis de 2008 y 5 variables en común con Japón.
- *Datos colombianos.* El dataset de rentabilidades de los fondos de inversión colectiva (FIC) no sirve para entrenar ni para contrastar, porque no tiene datos por persona. Se usa como contexto.
- *Análisis exploratorio.* La venta es más frecuente entre quienes fallan las preguntas de conocimiento financiero y entre los sobreconfiados, como dice la literatura. Las asociaciones son significativas pero pequeñas.
- *Reglas fijadas antes de entrenar.* Un protocolo define la partición, la validación, las métricas y la regla para elegir el modelo. El entrenamiento inicial está en curso.

Roles del equipo

Tabla 1. *Roles del equipo en el ciclo 2.*

Rol	Integrante
Product Owner y Product Tester	Jenny Paola Castellanos
Data Analyst y Design Thinker	Luis Guillermo Yépez
Technical Leader	Dilan Vega
Test Designer y Product Developer	Juan Gilberto Ayala

Fuente: elaboración propia.

2. Punto de partida: del perfil de riesgo a la reacción ante caídas

El ciclo 1 terminó con una decisión abierta. La encuesta IEFIC, elegida para el modelo de perfil, mostró que solo el 1,56 % de las personas tiene acciones, fondos o derivados, y no pregunta la tolerancia al riesgo. Además, el tutor pidió que cada decisión del proyecto saliera de artículos leídos.

2.1 Estado del arte

El 9 y el 10 de octubre revisamos la literatura y los datos abiertos. Buscamos en los cuatro repositorios sugeridos por el tutor (Hugging Face, Zenodo, Harvard Dataverse y opendata.org) y en fuentes oficiales, y excluimos los datos sintéticos, los agregados sin una fila por persona y los conjuntos sin una conducta ante una caída real. Resultado: 47 documentos con ficha de lectura y 11 datasets abiertos y verificados, registrados en el documento «Grupo-10 - Estado del arte v1.1» y en su Excel de soporte.

2.2 Nuevo objetivo del modelo

El modelo predice si una persona con inversiones vende todo o parte, o mantiene, durante una caída del mercado. La app usa esa predicción para enseñar, no para recomendar activos. El modelo responde «qué hicieron personas con respuestas parecidas en una caída real de otro país», no «lo que usted hará».

La literatura dejó ocho hipótesis. Este ciclo prepara los datos para probar las seis primeras; H7 y H8 necesitan datos propios de la app.

Tabla 2. *Hipótesis del proyecto (estado del arte, hoja 4).*

N.º	Hipótesis	Datos
H1	A menos conocimiento financiero, mayor probabilidad de haber vendido en la caída	Japón; NFCS como contraste
H2	El exceso de confianza se asocia con más venta, además del conocimiento	Japón
H3	Un modelo con solo respuestas de cuestionario discrimina mejor que el azar, pero bastante peor que uno con historial de portafolio	Japón
H4	Los modelos de árboles no superan a la regresión logística por más que la variación entre particiones	Japón y panel SCF
H5	La tolerancia al riesgo declarada no tiene un efecto de signo estable sobre vender	Japón, panel SCF, EE. UU. 2020, NFCS
H6	La calibración se deteriora más que la discriminación al pasar a otra población	Japón → panel SCF
H7	Lo que una persona dice que haría ante una caída coincide poco con lo que hace	Datos de la app
H8	Mostrar la caída antes del cuestionario reduce la tolerancia que la persona declara	Datos de la app

Fuente: elaboración propia.

2.3 Sondeos exploratorios

Antes de elegir la fuente, entrenamos modelos sin ajustar sobre Japón, el panel SCF 2007-2009 y una encuesta de EE. UU. de abril de 2020, para ver si había señal. El AUROC quedó entre 0,57 y 0,77 según la fuente y el objetivo, y marcamos un caso como «no usar» por fuga de información. Son pruebas para decidir, no resultados del proyecto.

3. Sprints 3 y 4. Tarea 1: selección, limpieza, construcción, integración y formateo

3.1 Selección final de datos

La encuesta japonesa entrena el modelo porque es la única fuente pública grande que mide, en las mismas personas, conocimiento financiero, confianza en lo que saben y qué hicieron en una caída real. Los demás datasets sirven para probar el modelo fuera de Japón o para ver si los efectos van en la misma dirección.

Tabla 3. *Datasets del proyecto y su uso.*

Dataset	Uso	Qué mide
Encuesta japonesa (Bawalle et al., 2025)	Entrenar	191.762 clientes de un corredor en línea; 54.704 tenían inversiones en marzo de 2020 y 10.869 vendieron todo o parte

Dataset	Uso	Qué mide
Panel SCF 2007-2009 (Reserva Federal)	Probar fuera de Japón	3.857 familias entrevistadas en 2007 y 2009; 1.563 tenían acciones o fondos y unas 311 salieron (19,9 %)
Hanspal, Weber y Wohlfart (EE. UU., 2020)	Segunda prueba fuera de Japón	4.567 inversionistas; 1.036 redujeron su proporción en acciones
NFCS Investor Survey 2018 (FINRA)	Dirección de los efectos; lo dicho frente a lo hecho	87 de 1.942 vendieron en febrero de 2018; de 128 que dijeron que venderían, vendieron 35
CRR 2009 Retirement Survey	Dirección de los efectos	262 de 1.269 trabajadores pasaron su cuenta de retiro a bonos o efectivo en 2008
Encuesta coreana de fondos (Chung y Kim)	Dirección de los efectos	De 581 personas que invertían en 2007, 126 ya no invertían en 2008

Fuente: elaboración propia.

Cada integrante descarga los archivos desde su fuente original. Los datos no se suben al repositorio, y los de la NFCS no se comparten entre integrantes porque sus términos de uso lo prohíben. El detalle de fuentes y licencias está en docs/datos.md.

3.1.1 Datos colombianos

Como la app es para inversionistas colombianos, buscamos datos de Colombia que pudieran reemplazar al panel SCF en el contraste. Jenny evaluó el dataset «Rentabilidades de los Fondos de Inversión Colectiva» de la Superintendencia Financiera (datos.gov.co): 2.960.756 registros de 1.018 fondos, de 2016 a 2026. Cada fila es un fondo en un día, con aportes, retiros, número de inversionistas y rentabilidad.

Conclusión: no sirve para entrenar ni para contrastar, porque no dice quién retiró ni trae edad, educación o ingreso. Para usarlo en lugar del SCF haría falta una fila por persona y saber si esa persona vendió o mantuvo. Lo conservamos como contexto. El Banco de la República (2020) reporta que en marzo de 2020 se retiraron cerca de 24,7 billones de pesos de los FIC, pero el número de inversionistas, de unos 1,4 millones, cayó solo 2,6 %. Los reportes no separan personas de empresas.

3.2 Limpieza de datos

El script bolsalab/dataset.py lee el archivo original del artículo y deja solo a quienes vendieron todo, vendieron parte o mantuvieron. Quien no tenía inversiones queda fuera: no tenía nada que vender, y mezclarlo con quien mantuvo enseñaría al modelo a separar inversionistas de no inversionistas.

Tabla 4. *Población antes y después del filtro.*

Grupo	Personas
Encuestados en el archivo original	191.762
Vendieron todo	2.379
Vendieron parte	8.490
Mantuvieron	43.835
Población de entrenamiento	**54.704** (vendió todo o parte el 19,87 %)

Fuente: elaboración propia.

Antes de entrenar fijamos los valores que deben dar los datos. Las pruebas automáticas los comparan cada vez que se corre el código. Si una falla, nadie entrena hasta encontrar la causa.

Tabla 5. *Verificaciones de calidad sobre el archivo original.*

Prueba	Valor esperado y obtenido
Filas y columnas	191.762 × 26
Celdas vacías	0
Personas con más de una conducta marcada	0
Edad	18 a 94 años
Tres preguntas de conocimiento y seis variables binarias	Solo 0 o 1
Confianza en lo que sabe y visión de corto plazo	1 a 5
Aversión al riesgo	0,0 a 1,0, en pasos de 0,1
Ingreso y activos del hogar	12 y 10 tramos

Fuente: elaboración propia.

Ningún valor quedó fuera de su escala, así que no eliminamos ni corregimos registros. Hay 452 personas que repiten las 17 respuestas de otra, y 329 que repiten también el resultado. Las conservamos: con preguntas cerradas, dos personas distintas pueden responder igual.

3.3 Construcción de nuevos datos

El script bolsalab/features.py construye la variable objetivo y las variables de entrada. La variable objetivo, sold, vale 1 si la persona vendió todo o parte durante la caída y 0 si mantuvo. Usa la misma definición de los autores: venta de pánico es «the complete or partial liquidation of stocks».

Tabla 6. *Variables de entrada del modelo.*

Variable	Qué mide	Valores
knows_interest, knows_inflation, knows_diversification	Acierto en cada pregunta de conocimiento financiero	0 o 1
knowledge_confidence	Cuánto cree saber de finanzas	1 a 5
overconfidence	Exceso de confianza (columna de los autores)	0 o 1
age, age_squared	Edad y edad al cuadrado	18 a 94
male, university, married, has_children, urban, employed	Sexo, título universitario, estado civil, hijos, zona urbana y empleo	0 o 1
income_bracket, assets_bracket	Tramo de ingreso y de activos financieros del hogar	1 a 12 y 1 a 10
risk_aversion	Preferencia por no arriesgar	0 a 1
short_term_view	Atención al corto plazo	1 a 5

Fuente: elaboración propia.

Decisiones principales, documentadas en docs/variables.md:

- *Las tres preguntas de conocimiento entran por separado.* Así el modelo aprende cuál pesa más y la app sabe qué pregunta falló cada persona. El conocimiento financiero es el único predictor con dirección estable en los estudios leídos (Bucher-Koenen y Ziegelmeyer, 2011; Bawalle et al., 2025). Las preguntas siguen la redacción estándar de Lusardi y Mitchell (2014).
- *La edad entra también al cuadrado.* La venta forma una U con la edad: vendió el 28,1 % de quienes tienen 18 a 24 años, entre 17 y 19 % en edades medias y el 25,5 % desde los 60. La regresión logística solo capta esa forma con el término cuadrático, igual que en Bawalle et al. (2025).
- *El exceso de confianza usa la columna de los autores,* para comparar con su resultado (hipótesis H2).

- *Ingreso y activos entran como número de tramo.* El archivo guarda cada tramo como una cifra en yenes; se cambia por su posición (1, 2, 3…), que es como los preguntará la app.

3.4 Revisión de fugas de información

Una fuga ocurre cuando el modelo recibe como entrada algo que contiene el resultado (Kapoor y Narayanan, 2023). Excluimos estas columnas, y una prueba automática falla si alguna columna de conducta entra al modelo:

Tabla 7. *Columnas del archivo que no entran al modelo.*

Columna	Por qué no entra
Tot_Panic_Sell, Part_Panic_Sell, Cons_Investor	Con ellas se construye sold: usarlas sería una fuga
FinLit_Score, Fin_Literacy	Suma de las tres preguntas de conocimiento, que ya entran por separado
AgeGroup	Repite la edad en tres tramos
lH_Income, lH_Asset	Repiten los tramos de ingreso y activos, en logaritmo
FinLit_Underconfidence	Su regla en el archivo no sigue la definición del artículo y ninguna hipótesis la usa

Fuente: elaboración propia.

Las respuestas se dieron a finales de 2023, después de la caída. Alguien que vendió y se arrepintió pudo declararse después más averso al riesgo. El código no puede corregirlo, así que lo declaramos como límite y el panel SCF, que midió antes de la crisis, sirve de contraste.

3.5 Integración de datos

La tabla de entrenamiento une en una fila por persona las variables cognitivas (conocimiento y confianza), demográficas y financieras. No se unen los 11 datasets en una sola tabla, porque cada uno mide «vender» de forma distinta y hace preguntas distintas. La integración que sí hacemos es entre Japón y el panel SCF: identificamos las cinco variables que existen en las dos encuestas, todas demográficas.

Tabla 8. *Tabla del panel SCF 2007-2009 para el contraste (bolsalab/scf_panel.py).*

Elemento	Definición
Población	Familias que tenían acciones o fondos en 2007 (1.563)
sold	1 si en 2009 ya no tenían acciones ni fondos; 0 si seguían teniéndolos
Variables comunes	age, university, married, has_children y employed, con los mismos nombres que en Japón
Imputaciones	La Reserva Federal publica 5 versiones de cada familia; queda una fila por familia y versión

Fuente: elaboración propia.

El panel no trae las preguntas de conocimiento ni de confianza. Por eso la prueba en EE. UU. solo cubre la parte demográfica del modelo.

3.6 Formateo de datos

- Nombres de columnas en inglés y en minúscula, iguales a los que usa la app (por ejemplo, knows_interest).

- Tablas en formato parquet: data/interim/japan_investors.parquet (población) y data/processed/japan_training.parquet (54.704 filas, 17 variables y sold).
- El escalado y las demás transformaciones se ajustan dentro del pipeline de entrenamiento, solo con los datos de entrenamiento, para evitar fugas.
- Flujo reproducible: dataset.py → features.py, y scf_panel.py para el contraste. Las 23 pruebas automáticas se reparten así: 9 en la limpieza, 7 en las variables y 7 en el panel SCF.

3.7 Análisis exploratorio de datos

El análisis exploratorio, a cargo de Luis, se hizo sobre la tabla de entrenamiento y está en el notebook «Grupo-10 - Análisis exploratorio de datos (EDA)». Confirmó la estructura (54.704 × 18, sin vacíos) y el desbalance (19,87 % de ventas), y mostró que age_squared coincide con la edad al cuadrado en todas las filas.

Tabla 9. *Asociaciones más altas entre variables (Spearman).*

Variables	Coeficiente
knowledge_confidence – overconfidence	0,421
knows_interest – knows_inflation	0,352
income_bracket – assets_bracket	0,345
age – assets_bracket	0,332
knows_inflation – knows_diversification	0,312

Fuente: elaboración propia.

La correlación más alta es esperable: el exceso de confianza se construye a partir de la confianza y los aciertos. Ninguna pareja pasa de 0,43.

Tabla 10. *Porcentaje que vendió según algunas características.*

Característica	Sí	No
Conoce la diversificación	17,59 %	27,99 %
Exceso de confianza	28,19 %	19,19 %
Hombre	23,68 %	12,12 %
Empleado	19,24 %	26,94 %

Fuente: elaboración propia.

Con pruebas chi-cuadrado y corrección de Holm, la venta se asocia de forma significativa con el sexo, las tres preguntas de conocimiento, el exceso de confianza, el empleo y el título universitario. No se asocia con estado civil, hijos ni zona urbana. Todos los tamaños de efecto son pequeños: el mayor es el del sexo (V de Cramér ≈ 0,136), seguido del conocimiento de diversificación (≈ 0,108).

Tabla 11. *Lo que esperábamos y lo que vimos.*

Hipótesis	Esperábamos	Vimos en el análisis exploratorio
H1	Más venta con menos conocimiento	Vende el 27,99 % de quien falla la diversificación frente al 17,59 % de quien acierta; las tres preguntas son significativas
H2	Más venta con exceso de confianza	28,19 % frente a 19,19 %, significativa
H3	Señal modesta con solo un cuestionario	Todos los efectos son pequeños (V de Cramér ≤ 0,136)
H5	Sin efecto estable de la aversión al riesgo	Medias muy parecidas: 0,563 entre quienes vendieron y 0,541 entre quienes mantuvieron

Fuente: elaboración propia.

Son asociaciones descriptivas, una variable a la vez. No prueban causa, y la prueba formal de cada hipótesis se hace con el modelo en el ciclo 3A. El análisis exploratorio sugiere además medir exactitud, precisión, sensibilidad y F1. El protocolo las deja fuera porque la app no responde sí o no: muestra una categoría basada en probabilidades, y para eso importan la discriminación y la calibración (sección 4).

4. Preparación para el modelado

4.1 Protocolo de evaluación

Fijamos las reglas antes de entrenar, para comparar los modelos en igualdad de condiciones y que nadie elija el ganador después de ver los resultados. Están en docs/protocolo-evaluacion.md.

Tabla 12. *Reglas del protocolo.*

Regla	Decisión	Respaldo
Partición	20 % de prueba con la misma proporción de ventas, que nadie toca hasta evaluar el modelo elegido; semilla 42 para todos	Decisión del equipo
Validación	Cruzada anidada sobre el 80 %: 5 particiones para medir y 3 para elegir hiperparámetros	Varma y Simon (2006)
Desbalance	Sin SMOTE, remuestreo ni pesos por clase; si hace falta, se mueve el umbral	van den Goorbergh et al. (2022)
Métrica principal	AUROC, con su intervalo de confianza del 95 % en el conjunto de prueba	McDermott et al. (2024)
Otras métricas	AUPRC (azar = 0,199), calibración, Brier y beneficio neto	Van Calster et al. (2019); Assel et al. (2017); Vickers et al. (2019)
Ganador	Mayor AUROC medio, salvo que uno más simple quede a menos de una desviación estándar	McElfresh et al. (2023)
Alarma	Revisar fugas si el AUROC llega a 0,82 o más (el valor de Elkind et al. con historial de portafolio)	Elkind et al. (2022)
Qué ve el usuario	Si es más, igual o menos propenso a vender que el promedio; nunca la probabilidad	Riley et al. (2024)

Fuente: elaboración propia.

Tabla 13. *Modelos y responsables.*

Modelo	Responsable	Por qué entra
Trivial (siempre 19,87 %)	Jenny	Es el piso: un modelo que no lo supera no sirve
Regresión logística regularizada	Jenny	La usa el dominio (Bawalle et al., 2025; van Smeden et al., 2019)
Random Forest	Luis	Referencia en datos tabulares (McElfresh et al., 2023)
XGBoost, LightGBM y CatBoost	Dilan	Los mejores en tablas pequeñas y medianas (Grinsztajn et al., 2022)
Red neuronal pequeña	Juan	Único precedente en venta de pánico (Elkind et al., 2022)

Fuente: elaboración propia.

4.2 Entrenamiento inicial

Dilan, como Technical Leader, adelanta el entrenamiento inicial con las 17 variables y la variable sold, siguiendo el protocolo. El 19 de octubre integramos su archivo de experimentos a la rama feature/training del

repositorio. El equipo presentará los resultados en el ciclo 3A, con todos los modelos de la tabla anterior y la regla de selección aplicada.

5. Supuestos y límites

- *Datos de otro país.* No hay datos individuales públicos de Colombia ni de América Latina: el modelo aprende de clientes de un corredor en línea de Japón.
- *Respuestas posteriores a la caída.* La encuesta se respondió a finales de 2023 sobre lo que la persona hizo en marzo de 2020.
- *Significado de Cons_Investor.* Dedujimos que significa «mantuvo» a partir de la Tabla 1 del artículo y de los conteos.
- *Exceso de confianza.* La columna del archivo no sigue la definición del artículo en 3.450 personas, pero su promedio (0,07) coincide con el publicado: los autores la usaron así.
- *Escala de confianza.* En el archivo, quien marca 5 acierta más (2,64 frente a 1,98 aciertos), así que deducimos que el archivo invirtió la escala del cuestionario. La app debe preguntar en el sentido del archivo.
- *Contraste parcial.* El panel SCF solo permite probar la parte demográfica del modelo, y allí «vender» significa salir por completo de acciones y fondos.
- *Asociación no es causa.* Los resultados del análisis exploratorio describen asociaciones.

6. Aprendizajes y próximos pasos

6.1 Aprendizajes

- Leer antes de decidir cambió el proyecto: el estado del arte mostró que la venta en una caída real sí se puede medir con datos públicos por persona, algo que la IEFIC no permitía.
- Fijar las reglas antes de entrenar evita ajustar las decisiones al resultado.
- Las pruebas automáticas y la documentación en el repositorio permiten que cualquier integrante reproduzca la tabla y verifique cada cifra.
- Buscar datos colombianos dejó clara la condición que debe cumplir una fuente local: una fila por persona y su conducta en una caída.

6.2 Próximos pasos (ciclo 3A)

Tabla 14. *Acciones para el siguiente ciclo.*

Acción	Responsable
Entrenamiento oficial y comparación de los modelos con la regla del protocolo	Dilan, con todo el equipo
Contraste en EE. UU.: entrenar en Japón con las 5 variables comunes y medir discriminación y calibración en el panel SCF (H6)	Juan
Cerrar el análisis exploratorio y la redacción de las preguntas de riesgo	Luis y Jenny
Definir los tramos de ingreso y activos en pesos, y adaptar las preguntas de conocimiento al español de Colombia	Luis y Jenny

Fuente: elaboración propia.

Referencias

Assel, M., Sjoberg, D. D., & Vickers, A. J. (2017). The Brier score does not evaluate the clinical utility of diagnostic tests or prediction models. Diagnostic and Prognostic Research, 1, 19.

Banco de la República. (2020). Reporte de Estabilidad Financiera, primer semestre de 2020.

Bawalle, A. A., Khan, M. S. R., & Kadoya, Y. (2025). Overconfidence, financial literacy, and panic selling: Evidence from Japan. PLOS ONE, 20(3), e0315622. https://doi.org/10.1371/journal.pone.0315622

Board of Governors of the Federal Reserve System. 2007-09 Panel Survey of Consumer Finances [datos]. https://www.federalreserve.gov/econres/scf_2009p.htm

Bucher-Koenen, T., & Ziegelmeyer, M. (2011). Who lost the most? Financial literacy, cognitive abilities, and the financial crisis (ECB Working Paper No. 1299).

Elkind, D., Kaminski, K., Lo, A. W., Siah, K. W., & Wong, C. H. (2022). When do investors freak out? Machine learning predictions of panic selling. The Journal of Financial Data Science, 4(1), 11–39.

FINRA Investor Education Foundation. National Financial Capability Study, Investor Survey 2018 [datos]. https://www.finrafoundation.org/knowledge-we-gain-share/nfcs/data-and-downloads

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? NeurIPS 35.

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. Patterns, 4(9), 100804.

Lusardi, A., & Mitchell, O. S. (2014). The economic importance of financial literacy: Theory and evidence. Journal of Economic Literature, 52(1), 5–44. https://doi.org/10.1257/jel.52.1.5

McDermott, M. B. A., et al. (2024). A closer look at AUROC and AUPRC under class imbalance. NeurIPS 2024.

McElfresh, D., et al. (2023). When do neural nets outperform boosted trees on tabular data? NeurIPS 36.

Riley, R. D., et al. (2024). Evaluation of clinical prediction models (part 2): How to undertake an external validation study. BMJ, 384, e074820.

Superintendencia Financiera de Colombia. Rentabilidades de los Fondos de Inversión Colectiva (FIC) [datos]. https://www.datos.gov.co/Hacienda-y-Cr-dito-P-blico/Rentabilidades-de-los-Fondos-de-Inversi-n-Colectiv/qhpu-8ixx

Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., & Steyerberg, E. W. (2019). Calibration: The Achilles heel of predictive analytics. BMC Medicine, 17, 230.

van den Goorbergh, R., van Smeden, M., Timmerman, D., & Van Calster, B. (2022). The harm of class imbalance corrections for risk prediction models. JAMIA, 29(9), 1525–1534.

van Smeden, M., et al. (2019). Sample size for binary logistic prediction models: Beyond events per variable criteria. Statistical Methods in Medical Research, 28(8), 2455–2474.

Varma, S., & Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. BMC Bioinformatics, 7, 91.

Vickers, A. J., van Calster, B., & Steyerberg, E. W. (2019). A simple, step-by-step guide to interpreting decision curve analysis. Diagnostic and Prognostic Research, 3, 18.

Anexos

Archivos que acompañan esta entrega:

- Grupo-10 - Backlog Ciclo 2 (actividades, responsables, herramientas de Design Thinking y entregables).
- Grupo-10 - Retrospectiva Ciclo 2.
- Grupo-10 - Análisis exploratorio de datos (EDA).

- Grupo-10 - Estado del arte v1.1 (soporte de las decisiones de este ciclo).

Repositorio del proyecto: https://github.com/EspecializacionIA1/bolsalab. Contiene el código del pipeline (bolsalab/dataset.py, bolsalab/features.py y bolsalab/scf_panel.py), las pruebas automáticas (tests/) y la documentación (docs/datos.md, docs/variables.md y docs/protocolo-evaluacion.md).