Pontificia Universidad Javeriana · Especialización en Inteligencia Artificial

Proyecto de Aplicación en IA

BolsaLAB

Estado del arte y metodología derivada

Predicción de la reacción de un inversionista ante una caída del mercado

Grupo 10

Jenny Paola Castellanos
Luis Guillermo Yépez
Dilan Vega
Juan Gilberto Ayala

Versión 1.1 · Octubre de 2026

1. Resumen

BolsaLAB es un copiloto educativo para personas colombianas que empiezan a invertir. El equipo decidió que el modelo que entrenará desde cero estime **qué hace una persona cuando el mercado cae**: vender o mantener. Este documento revisa la literatura sobre esa conducta, inventaría los datos públicos con los que se puede entrenar y deriva las variables, los modelos, las hipótesis y la metodología del proyecto.

- **Vender en una caída es conducta de minoría y se predice poco.** Según la definición, vende entre el 1 % y el 25 % de los inversionistas. De los estudios leídos, solo uno usa aprendizaje automático con validación fuera de muestra, y lo hace con el historial del portafolio, que un cuestionario no tiene (Elkind et al., 2022).
- **El conocimiento financiero es el único predictor de cuestionario con dirección estable:** quien sabe menos vende más, en Alemania en 2008 y en Japón en 2020. La tolerancia al riesgo declarada, la edad y la riqueza cambian de signo entre estudios.
- **Hay datos públicos para entrenar.** Se abrieron y verificaron once conjuntos. Los tres más útiles son una encuesta japonesa sobre marzo de 2020 (54.704 personas con inversiones), el panel de la Survey of Consumer Finances 2007-2009 de Estados Unidos (características medidas antes de la caída) y una encuesta de Estados Unidos de abril de 2020 alojada en Harvard Dataverse.
- **Hay señal, y es modesta.** En sondeos exploratorios con esos tres conjuntos, la capacidad de discriminación (AUROC) queda entre 0,57 y 0,70, y la regresión logística rinde casi igual que los modelos de árboles.
- **Propuesta:** un clasificador binario, "vendió todo o parte" frente a "mantuvo", entrenado solo con personas que tenían inversiones, con la encuesta japonesa como base y el panel de 2007-2009 como contraste.

> **Tres límites que se declaran desde el inicio.** No se encontró ningún dato individual de Colombia ni de América Latina para entrenar o validar. Ningún estudio leído demuestra que una respuesta hipotética o la conducta en un simulador predigan lo que la persona hace con su dinero. Por eso el modelo estima "qué hicieron personas con respuestas parecidas en una caída real de otro país", no "lo que usted hará".

2. Pregunta y método de revisión

Pregunta. ¿Cuál es el estado del arte sobre la predicción de cómo reacciona un inversionista minorista ante una caída del mercado, con qué datos públicos se puede entrenar ese modelo y qué metodología se deriva de la literatura?

Términos. *Renta variable*: acciones y fondos de acciones. *AUROC*: probabilidad de que el modelo dé más puntaje a una persona que vendió que a una que no; 0,5 es azar y 1 es perfecto. *Tasa base*: proporción de personas que presenta la conducta. *Calibración*: que una probabilidad predicha de 20 % corresponda a que 20 de cada 100 personas así realmente vendan.

Aspecto	Cómo se hizo

Líneas de búsqueda	Cinco: estudios que explican o predicen la venta en caídas; fundamentos conductuales y cómo se miden; datos en repositorios abiertos; encuestas y paneles oficiales; metodología para eventos poco frecuentes y contexto de Colombia y Chile
Fuentes de literatura	OpenAlex, Crossref, Europe PMC, NBER, repositorios de universidades y bancos centrales, Banco de la República, Superintendencia de Pensiones de Chile
Criterios de inclusión	Estudios con personas u hogares reales que miden una reacción ante una caída o una pérdida; estudios que miden con preguntas los rasgos que la explican; experimentos de inversión; literatura metodológica; documentos oficiales de Colombia y Chile
Criterios de exclusión	Datos sintéticos o de personas simuladas, textos para modelos de lenguaje, agregados sin fila por persona, conjuntos sin variable de reacción, y estudios que predicen caídas del mercado y no la conducta de la persona
Regla de lectura	Solo sustentan decisiones los documentos cuyo texto se leyó. Cada cifra se registró con su tabla, sección o página
Resultado	47 documentos con ficha de lectura y 11 conjuntos de datos abiertos y verificados. Fechas: 9 y 10 de octubre de 2026

Los cuatro repositorios recomendados por el tutor

Repositorio	Consultas	Resultado
Hugging Face	59 por nombre y 19 de texto completo	Ningún conjunto utilizable: textos para modelos de lenguaje, personas simuladas y datos sintéticos
Zenodo	37 con frase exacta	Dos utilizables: 1.526 inversionistas de China y Vietnam sobre 2022, y 407 de Turquía con una pregunta hipotética
Harvard Dataverse	44	Uno utilizable y fuerte: encuesta de Hanspal, Weber y Wohlfart, Estados Unidos, abril de 2020, 7.447 personas, licencia CC0
opendata.org	Revisión de sus páginas	No es un repositorio de datos de investigación: se describe como un directorio de organizaciones, personas y lugares

Los demás conjuntos salieron de la revista PLOS ONE, la Reserva Federal, FINRA, Boston College, Mendeley Data, la Universidad de Glasgow y OSF.

> **Límites de la revisión.** Cubre solo acceso abierto y casi todo en inglés. No se consultaron Scopus, Web of Science ni Google Scholar. Casi todas las lecturas fueron por secciones (diseño, instrumento y resultados), y al menos diez artículos se leyeron en su versión de documento de trabajo, cuyas cifras pueden diferir de la versión publicada. Los criterios de la tabla se documentaron a partir de las bitácoras de búsqueda.

3. Por qué importa el problema

- **Cuántos venden depende de cómo se cuente.** Con registros de un corredor de Estados Unidos y una definición estricta, el 9,0 % de los hogares lo hizo alguna vez en 13 años (Elkind et al., 2022). En Japón, el 1,24 % dijo haber vendido todo y el 4,43 % una parte en marzo de 2020 (Bawalle et al., 2025). Entre hogares alemanes con pérdidas en 2008, el 75,2 % mantuvo, el 11,6 % vendió parte y el 13,2 % vendió todo (Bucher-Koenen y Ziegelmeyer, 2011).

- **Qué pasa con quienes venden.** El 30,9 % de quienes liquidaron no había vuelto a tener activos de riesgo al cierre de 2015 (Elkind et al., 2022). La evidencia no va en una sola dirección: en planes de retiro de Estados Unidos en 2020 no se halló que cambiar el portafolio redujera el retorno del trimestre (Blanchett et al., 2020).
- **Chile.** El regulador calculó el resultado de cada afiliado que cambió de fondo de pensiones entre 2014 y 2021: el 77,5 % obtuvo peor resultado que si se hubiera quedado en su fondo inicial (Fuentes et al., 2022). En 2020 hubo 9,8 millones de traslados, frente a 1,9 millones en 2019.
- **Colombia.** En marzo de 2020 se retiraron cerca de 24,7 billones de pesos de los fondos de inversión colectiva. El Banco de la República aclara que no fue una salida masiva de inversionistas: de unos 1,4 millones, el número cayó 2,6 % (Banco de la República, 2020a). Los reportes no separan personas naturales de empresas, así que el episodio no se puede atribuir a inversionistas minoristas.

4. Qué dice la literatura

4.1 Quién vende en una caída

- **Conocimiento financiero.** Se mide con tres preguntas con respuesta correcta sobre interés, inflación y diversificación (Lusardi y Mitchell, 2014). En Alemania, responder bien las tres se asocia con 11,8 puntos porcentuales menos de probabilidad de vender; vendió el 21 % de quienes aciertan las tres frente al 36 % del resto. Ese estudio midió el conocimiento en 2007, antes de la crisis (Bucher-Koenen y Ziegelmeyer, 2011, Tabla 6). En Japón el efecto va en la misma dirección (Bawalle et al., 2025, Tabla 3; Lal et al., 2024).
- **Exceso de confianza.** Tener puntaje bajo en las tres preguntas y aun así declarar confianza en el propio conocimiento se asocia con más venta (Bawalle et al., 2025, Tabla 3).
- **Tolerancia al riesgo declarada.** Predice cuánto riesgo toma la persona, pero su efecto sobre vender en una caída se contradice: ninguno en Alemania; en Japón vendieron más los más aversos al riesgo.
- **Edad, riqueza e ingreso.** Cambian de signo según la definición. "Cambió algo en su portafolio" mide actividad, que crece con la riqueza; "vendió todo" mide abandono, que decrece con ella (Blanchett et al., 2020, frente a Bawalle et al., 2025). Por eso el objetivo del modelo no debe mezclar "operó" con "vendió".
- **Sexo.** Los hombres venden y operan más en casi todos los estudios, con excepciones.

4.2 Fundamentos conductuales

- **Aversión a la pérdida** (perder 100 duele más de lo que alegra ganar 100). Se mide con seis preguntas de "lanzar o no una moneda" (Gächter et al., 2022). Ningún estudio leído prueba que esa medida prediga vender en una caída real.
- **Ver los resultados muy seguido reduce el riesgo que se toma.** En el experimento original, ver el resultado ronda por ronda bajó la apuesta de 67,4 % a 50,5 % (Gneezy y Potters, 1997, Tabla I). Con adultos que invirtieron en fondos reales durante un año, el efecto fue de 0,0 puntos (Beshears et al., 2017). Los efectos de laboratorio se encogen en condiciones reales.
- **Experiencia y miedo.** En un panel de clientes italianos, quienes eligen "ningún riesgo" pasaron de 16 % a 43 % entre 2007 y 2009 (Guiso et al., 2018). Mostrar un gráfico de caída antes de una tarea con dinero real redujo la inversión de 58 % a 45 % (Cohn et al., 2015, Tabla 3).

4.3 Simuladores y preguntas hipotéticas

- **Lo que un simulador sí cambia.** Simular antes de invertir subió la inversión inicial y la sensación de estar informado, pero no cambió cómo reaccionaron las personas después de perder (Bradbury et al., 2019). Una réplica con 3.804 participantes no encontró ni el efecto inicial (Lejarraga et al., 2024).
- **Lo que no está demostrado.** No se encontró ningún estudio que use la conducta en un simulador para predecir la conducta real, ni uno que pregunte "qué haría si el mercado cae 20 %" y luego observe a la misma persona en una caída real.
- **El único dato público que compara lo dicho con lo hecho.** En la encuesta NFCS de 2018, de 128 personas que dijeron que venderían ante una caída de 20 %, solo 35 habían vendido en la caída real de febrero de ese año (cruce propio sobre el archivo, sin ponderar).

Consecuencia para el producto: el simulador es una herramienta para entender el riesgo, y una pregunta hipotética sirve como variable de entrada, no como etiqueta del modelo.

4.4 Metodología para un evento poco frecuente, declarado y medido en otra población

- **Evento poco frecuente.** La regresión logística subestima la probabilidad de eventos raros (King y Zeng, 2001). La regla de "10 eventos por variable" no sirve para fijar el tamaño de muestra; se usan tres criterios (Riley et al., 2019; van Smeden et al., 2019).
- **Calibración.** Es lo primero que se rompe al cambiar de población (Van Calster et al., 2019). La métrica se elige según el error que importa, no por el desbalance (McDermott et al., 2024).
- **Etiqueta declarada.** Si una fracción de quienes vendieron no lo reporta, el orden de riesgo que produce el modelo se conserva, pero el nivel de probabilidad queda subestimado (Elkan y Noto, 2008).
- **Otra población.** Probar el modelo con datos de otro país mide si es transportable, no si funciona en Colombia (Riley et al., 2024). La guía TRIPOD+AI lista lo que se debe reportar en ese caso (Collins et al., 2024).

5. Comparación de los estudios centrales

Estudio	Datos	Qué mide y cuántos venden	Modelo y validación	Resultado principal
Elkind et al. (2022)	Registros de un corredor: 653.455 cuentas. EE. UU., 2003-2015. Privados	Caída de 90 % de la renta variable de la cuenta en un mes. 9,0 % de los hogares en 13 años	Logística y redes; partición 60/40 por hogar	AUROC 0,821 (red) y 0,739 (logística), con historial de portafolio. 30,9 % no había vuelto al mercado
Bawalle et al. (2025)	Encuesta a 191.762 clientes de un corredor. Japón, marzo de 2020. Públicos	Declarado: vendió todo 1,24 %; vendió parte 4,43 %	Probit; sin validación	Menos conocimiento, más venta; exceso de confianza, más venta. Pseudo R^2 de 0,039 y 0,027
Bucher-Koenen y Ziegelmeyer (2011)	Panel de hogares; 442 con pérdidas. Alemania, 2008	Mantuvo 75,2 %; vendió parte 11,6 %; vendió todo 13,2 %	Mínimos cuadrados; sin validación	Conocimiento medido antes de la crisis: 11,8 puntos menos de probabilidad de vender

Blanchett et al. (2020)	617.376 participantes de planes de retiro. EE. UU., 2020. Privados	Cualquier cambio de portafolio: 8,7 %	Probit; sin validación	Quien gestiona su cuenta tiene 9,8 puntos más de probabilidad de cambiar que quien delega
Giglio et al. (2020)	Encuesta enlazada con portafolios de Vanguard. EE. UU., 2020. Privados	Cambio activo de al menos 1 %. Cerca del 70 % no cambió	Descriptivo	Los más optimistas antes de la caída vendieron más; los movimientos fueron pequeños
Guiso et al. (2018)	666 clientes de un banco entrevistados en 2007 y 2009. Italia	"Ningún riesgo": de 16 % a 43 %	Regresiones	Quienes más aumentaron su aversión dejaron las acciones con más probabilidad
Fuentes et al. (2022)	22 millones de cambios de fondo de pensiones. Chile, 2014-2021	Cambio voluntario de fondo	Comparación de rentabilidad	77,5 % quedó peor que si no se hubiera movido
Bradbury et al. (2019)	551 adultos, experimento de 14 días. Alemania	Inversión con y sin simulación previa	Experimento	La simulación sube la inversión inicial; no cambia la reacción a pérdidas

Las cifras de Bucher-Koenen y Ziegelmeyer, Blanchett et al., Giglio et al., Guiso et al. y Bradbury et al. vienen de sus versiones de documento de trabajo.

6. De la literatura al diseño

6.1 Variables de entrada

Variable	Efecto sobre vender	Respaldo	Cómo se pregunta
Conocimiento financiero	Menos venta. Dirección estable	Bucher-Koenen y Ziegelmeyer (2011); Bawalle et al. (2025); Lal et al. (2024)	Tres preguntas de Lusardi y Mitchell sobre interés, inflación y diversificación, conservando la opción "no sabe"
Exceso de confianza	Más venta	Bawalle et al. (2025); Lal et al. (2024)	Autoevaluación del conocimiento, comparada con el puntaje de las tres preguntas
Sexo	Los hombres venden más, con excepciones	Bawalle et al. (2025); Elkind et al. (2022)	Pregunta directa
Tolerancia al riesgo declarada	Sin signo estable	Sin efecto en Alemania; más aversión, más venta en Japón	Pregunta de cuatro opciones de la Survey of Consumer Finances
Edad, ingreso, activos, educación	Cambian según el estudio	Bawalle et al. (2025); Bucher-Koenen y Ziegelmeyer (2011); Blanchett et al. (2020)	Por tramos
Reacción hipotética ante una caída de 20 %	Variable de entrada candidata, no etiqueta	Cruce propio en la encuesta NFCS 2018: 35 de 128	"Si el mercado cayera 20 % en poco tiempo, ¿qué haría?" (comprar, vender, nada, no sabe)

Aversión a la pérdida	Sin evidencia leída sobre vender	—	Seis preguntas de moneda (Gächter et al., 2022)

Las redacciones publicadas están en inglés; ninguna adaptación al español de Colombia está validada en lo leído.

6.2 Familias de modelos y su respaldo

Familia	Modelos	Referencia	Evidencia
Línea base trivial	Predecir la tasa base para todos	Assel et al. (2017); Vickers et al. (2019)	Toda métrica se lee junto a la del modelo trivial y frente a "avisar a todos"
Línea base interpretable	Regresión logística regularizada, con edad al cuadrado	Bawalle et al. (2025); van Smeden et al. (2019)	Es la familia que usa todo el dominio. La regularización mejora la predicción con pocos datos
Bosque de árboles	Random Forest	Breiman (2001)	Rango medio 8,26 en 98 conjuntos (McElfresh et al., 2023)
Boosting de árboles	XGBoost, LightGBM, CatBoost	Chen y Guestrin (2016); Ke et al. (2017); Prokhorenkova et al. (2018)	En tablas pequeñas y medianas igualan o superan a las redes (Grinsztajn et al., 2022; Shwartz-Ziv y Armon, 2022)
Red neuronal, opcional	Perceptrón multicapa	Elkind et al. (2022)	Único precedente del dominio, con 507 variables de portafolio. No es evidencia para un cuestionario corto

Sin respaldo para este proyecto: redes profundas para tablas pequeñas y el remuestreo tipo SMOTE como paso por defecto, que no mejora la discriminación y daña la calibración (van den Goorbergh et al., 2022).

7. Datos

Se abrieron once conjuntos. Todos son de fuera de América Latina. Las copias locales están en la carpeta *data/external* del repositorio, que no se versiona.

7.1 Inventario

Conjunto y origen	País y episodio	Variable objetivo y casos	Características medidas	Licencia
Encuesta Rakuten Securities–Universidad de Hiroshima. Archivo S1 de Bawalle et al. (2025), PLOS ONE	Japón, marzo de 2020	191.762 personas. Muestra de quienes tenían inversiones y vendieron o mantuvieron: 54.704; vendieron todo o parte 10.869 (19,87 %)	Después (2023)	El artículo es CC BY; sin licencia aparte para el archivo
Panel de la Survey of Consumer Finances 2007-2009. Reserva Federal	EE. UU., crisis de 2008	3.857 familias. Salió de la renta variable directa: 311 de 1.563 (19,9 %). Salió de toda la renta variable: 243 de 2.539 (9,6 %)	Antes (2007)	Descarga directa; sin licencia declarada

Hanspal, Weber y Wohlfart. Harvard Dataverse	EE. UU., abril de 2020	7.447 personas; 4.567 inversionistas: redujo su proporción en acciones 1.036, sin cambio 2.277, aumentó 1.254	Durante	CC0
NFCS Investor Survey 2018 y 2021. FINRA Foundation	EE. UU., caída de febrero de 2018	Vendió en la caída real: 87 de 1.942. "Vendería" ante una caída de 20 %: 279 de 4.051	Después	Solo uso académico; prohibido compartir los datos
CRR 2009 Retirement Survey. Boston College	EE. UU., crisis de 2008	1.317 trabajadores de 45 a 59 años. Movió su cuenta de retiro hacia bonos o efectivo: 262 de 1.269	Después	Uso no comercial con crédito
Encuesta coreana de inversionistas de fondos. Mendeley Data	Corea del Sur, 2007 y 2008	954 personas. De 581 que invertían en 2007, 126 ya no invertían en 2008	Antes (2007)	CC BY 4.0
Vuong et al. Zenodo	China y Vietnam, 2022	1.526 inversionistas. Consideró o actuó para vender y cortar pérdidas: no 414; pocas veces 642; muchas veces 470	Después	CC BY 4.0
Kozol. Zenodo	Turquía, 2024	407 inversionistas. Reacción hipotética a una caída de 20 %	Mismo momento	CC BY 4.0
FAR-Trans. Universidad de Glasgow	Un banco de Grecia, 2018 a 2022	Conducta registrada por el banco: 2.164 de 16.950 clientes (12,8 %) vendieron algo en la caída de 2020. Sin edad, sexo ni ingreso	Perfil previo	CC BY 4.0
Lejarraga et al. OSF	Reino Unido, juego de inversión	4.800 participantes y 142.440 decisiones	—	Sin licencia declarada
Schwaiger et al. OSF	Países Bajos y Austria, experimento	2.245 estudiantes y 53.805 decisiones por ronda	—	Sin licencia declarada

Conteos sin ponderar. Los enlaces y DOI de cada conjunto están en las referencias.

> **Sobre la muestra japonesa.** La encuesta preguntó qué hizo la persona en marzo de 2020, con siete opciones. El archivo trae una columna para quienes vendieron todo, otra para quienes vendieron parte y otra para quienes no cambiaron su portafolio. Con ellas se arma la muestra de 54.704 personas que tenían inversiones. Que esa tercera columna corresponda a las dos opciones de "mantuvo" se deduce de la Tabla 1 del artículo y de los conteos; conviene confirmarlo con los autores.

Colombia y América Latina. No se encontró ningún archivo público con una fila por persona sobre lo que hizo ante una caída del mercado. El Banco de la República y la Superintendencia de Pensiones de Chile publican solo agregados. Depender de datos de otros países es una condición del problema, no una elección de comodidad.

7.2 Sondeos exploratorios

Se probaron los tres conjuntos principales con modelos sin ajustar para saber si hay señal. No son resultados del proyecto: no tienen validación anidada ni pesos de encuesta.

Fuente y objetivo	Personas	Positivos	AUROC regresión	AUROC boosting	Tasa en el 10 % de mayor riesgo
Japón: vendió todo o parte, frente a mantuvo	54.704	19,87 %	0,648	0,659	39,0 %
Panel 2007-2009: salió de la renta variable directa	1.568 familias	19,9 %	0,703	0,696	42,9 %
Panel 2007-2009: salió de toda la renta variable	2.589 familias	9,5 %	0,773	0,770	30,8 %
EE. UU., abril de 2020: redujo su proporción en acciones	4.567	22,7 %	0,571	0,589	33,6 %

- **Hay señal y es modesta.** En Japón, el 10 % de personas con mayor probabilidad estimada vendió casi el doble que el promedio.
- **La regresión logística queda a menos de 0,02 de AUROC del boosting** en las tres fuentes.
- **La dirección coincide con la literatura.** En Japón vendió el 31,7 % de quienes no acertaron ninguna pregunta de conocimiento, frente al 17,1 % de quienes acertaron las tres. En el panel de 2007-2009 la salida baja con el nivel educativo, de 21,7 % a 5,3 %.

7.3 Opciones de entrenamiento y validación

Opción	A favor	En contra
A. Japón como base, con el panel 2007-2009 como contraste	Es la mayor. Única con las tres preguntas de conocimiento y la confianza, los dos predictores con dirección estable. Todas las entradas son de cuestionario. Tiene un artículo que modela el mismo objetivo con las mismas variables	Características medidas después del evento; conducta recordada tres años y ocho meses después; clientes de un corredor japonés; ingreso y activos en yenes
B. Panel 2007-2009 como base	Características medidas antes de la caída; conducta observada en las tenencias, no recordada	Menos de 500 casos positivos; sin preguntas de conocimiento financiero; "salir" mezcla la decisión de vender con otras causas; hogares de EE. UU. de hace 17 años
C. Encuesta de abril de 2020 como base	Licencia abierta; medición semanas después de la caída; tres direcciones con clases grandes	La señal más débil; conocimiento solo autoevaluado; mide "redujo su proporción", no "vendió"
D. Pregunta hipotética de la NFCS	Más casos que la caída real de 2018	Sin respaldo: sería predecir una intención. Solo 35 de 128 hicieron lo que dijeron

Lo que favorece la evidencia. La opción A, con el panel de 2007-2009 como contraste principal. Las dos debilidades de la encuesta japonesa (características medidas después y conducta recordada) son justo lo que el panel no tiene, y la dirección de los efectos coincide en ambos. La elección final corresponde al equipo y al tutor.

8. Hipótesis experimentales

N.º	Hipótesis	De dónde sale	Qué resultado la refuta
H1	A menos conocimiento financiero, mayor probabilidad de haber vendido en la caída	Bucher-Koenen y Ziegelmeyer (2011, Tabla 6); Bawalle et al. (2025, Tabla 3)	Que el efecto desaparezca o se invierta fuera de muestra
H2	El exceso de confianza se asocia con más venta, además del conocimiento	Bawalle et al. (2025, Tabla 3); Lal et al. (2024)	Que añadir la variable no cambie el desempeño ni tenga dirección estable
H3	Un modelo con solo respuestas de cuestionario discrimina mejor que el azar y bastante peor que el modelo con historial de portafolio	Elkind et al. (2022): AUROC 0,821; Bawalle et al. (2025): pseudo R^2 menor de 0,04	Un AUROC cuyo intervalo incluya 0,5, o uno cercano a 0,82, que obligaría a buscar una fuga de información
H4	Los modelos de árboles no superan a la regresión logística por más que la variación entre particiones	McElfresh et al. (2023); Göncü et al. (2026, Tabla 6); van Smeden et al. (2019)	Una ventaja del boosting mayor que esa variación y que se repita en otra fuente
H5	La tolerancia al riesgo declarada no tiene un efecto de signo estable sobre vender	Bucher-Koenen y Ziegelmeyer (2011); Bawalle et al. (2025); Hoffmann et al. (2013)	El mismo signo en todas las fuentes
H6	La calibración se deteriora más que la discriminación al pasar a otra población	Van Calster et al. (2019); King y Zeng (2001); Riley et al. (2024)	Una calibración que se conserve en la fuente externa
H7	Lo que una persona dice que haría ante una caída coincide poco con lo que hace	Cruce propio en la NFCS 2018 (35 de 128); Weber et al. (2013)	Concordancia alta entre lo dicho y lo hecho. Requiere datos de la aplicación
H8	Mostrar la caída antes del cuestionario reduce la tolerancia que la persona declara	Cohn et al. (2015); Guiso et al. (2018)	Ninguna diferencia entre los dos órdenes. Requiere datos de la aplicación

9. Metodología

Paso	Qué se hace	Referencia
1	Nombrar el objetivo con precisión: probabilidad de que una persona con ciertas respuestas haya vendido todo o parte de sus inversiones durante una caída real, frente a haberlas mantenido. No se mezcla con "operó"	Blanchett et al. (2020); Bawalle et al. (2025); Collins et al. (2024)
2	Fijar la población: solo personas que tenían inversiones en el momento de la caída	Collins et al. (2024)
3	Elegir la fuente de entrenamiento y las de contraste (sección 7.3)	Riley et al. (2024)

4	Justificar el tamaño de muestra con los tres criterios	Riley et al. (2019); van Smeden et al. (2019)
5	Diseñar el cuestionario de la aplicación copiando la redacción y la escala de los datos de entrenamiento, y documentar cada pregunta que no se pudo igualar	Lusardi y Mitchell (2014); Storkey (2009)
6	Aplicar el cuestionario antes del simulador y usar un único formato de simulador	Cohn et al. (2015); Guiso et al. (2018); Gneezy y Potters (1997)
7	Comparar una lista corta de modelos: trivial, regresión logística regularizada, Random Forest y boosting	van Smeden et al. (2019); McElfresh et al. (2023); Grinsztajn et al. (2022)
8	Validar sin fugas: validación cruzada anidada, preprocesamiento dentro del pipeline, particiones por familia donde haya varias filas por hogar, y revisar que ninguna entrada se haya medido después del resultado	Varma y Simon (2006); Cawley y Talbot (2010); Kapoor y Narayanan (2023); Wieczorek et al. (2022)
9	Tratar el desbalance sin remuestreo por defecto: pesos por clase y umbral ajustado	van den Goorbergh et al. (2022); Natarajan et al. (2013)
10	Medir discriminación, calibración y utilidad: AUROC y curva de precisión y exhaustividad con su línea de azar; curva de calibración; comparación con "avisar a todos"	McDermott et al. (2024); Van Calster et al. (2019); Vickers et al. (2019)
11	Contrastar en otras fuentes con las variables comunes y llamarlo transportabilidad, no validación para Colombia	Riley et al. (2024); Storkey (2009)
12	Explicar las predicciones con SHAP y contrastarlas con la tabla de variables	Lundberg y Lee (2017)
13	Desplegar con un mensaje honesto: una categoría relativa ("personas con respuestas parecidas a las suyas vendieron con más frecuencia en la caída de marzo de 2020"), no un porcentaje personal	Van Calster et al. (2019); King y Zeng (2001)
14	Reportar con la guía TRIPOD+AI y guardar, con consentimiento, las respuestas y decisiones de los usuarios para una validación local futura	Collins et al. (2024); Riley et al. (2024)

Vacíos que el proyecto puede llenar

1. No se encontró un modelo de solo cuestionario para la venta en caídas con validación fuera de muestra.
2. No se encontró ningún estudio con principiantes ni con América Latina.
3. La comparación entre lo que la persona dice que haría y lo que hizo, con los datos de la encuesta NFCS de 2018, no está publicada hasta donde se vio.
4. Nadie ha comparado la conducta en un simulador con un cuestionario y con la conducta posterior de las mismas personas. La aplicación puede producir el primer conjunto de ese tipo para Colombia.

La búsqueda detrás de estas cuatro afirmaciones no fue exhaustiva.

10. Limitaciones de la propuesta

- **Los datos son de otros países.** El modelo se entrena con una población y se usa con otra. La calibración en Colombia es desconocida.

- **La conducta de la fuente principal es recordada, no observada,** y sus características se midieron después de la caída.
- **La capacidad de predicción es modesta.** El resultado es una referencia de lo que hizo gente parecida, no un veredicto sobre el usuario.
- **Vender no siempre es un error.** La evidencia sobre el costo de vender no va en una sola dirección; los materiales del producto deben decirlo.
- **El simulador no está validado contra la conducta real** en ningún estudio leído.

11. Referencias

Assel, M., Sjoberg, D. D., & Vickers, A. J. (2017). The Brier score does not evaluate the clinical utility of diagnostic tests or prediction models. *Diagnostic and Prognostic Research, 1*, 19. https://doi.org/10.1186/s41512-017-0020-3

Banco de la República. (2020a). *Reporte de Estabilidad Financiera: primer semestre de 2020*. https://repositorio.banrep.gov.co/handle/20.500.12134/9848

Bawalle, A. A., Khan, M. S. R., & Kadoya, Y. (2025). Overconfidence, financial literacy, and panic selling: Evidence from Japan. *PLOS ONE, 20*(3), e0315622. https://doi.org/10.1371/journal.pone.0315622

Beshears, J., Choi, J. J., Laibson, D., & Madrian, B. C. (2017). Does aggregated returns disclosure increase portfolio risk taking? *The Review of Financial Studies, 30*(6), 1971–2005. https://doi.org/10.1093/rfs/hhw086 [leído en versión de trabajo NBER 16868]

Blanchett, D., Finke, M. S., & Reuter, J. (2020). *Portfolio delegation and 401(k) plan participant responses to COVID-19* (NBER Working Paper No. 27438). https://doi.org/10.3386/w27438

Board of Governors of the Federal Reserve System. (s. f.). *2007-09 Panel Survey of Consumer Finances* [datos]. https://www.federalreserve.gov/econres/scf_2009p.htm

Bradbury, M. A. S., Hens, T., & Zeisberger, S. (2019). How persistent are the effects of experience sampling on investor behavior? *Journal of Banking & Finance, 98*, 61–79. https://doi.org/10.1016/j.jbankfin.2018.10.014 [leído en versión de trabajo de 2016]

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324 [lectura parcial]

Bucher-Koenen, T., & Ziegelmeyer, M. (2011). *Who lost the most? Financial literacy, cognitive abilities, and the financial crisis* (ECB Working Paper No. 1299). https://www.ecb.europa.eu/pub/pdf/scpwps/ecbwp1299.pdf [publicado en 2014 en *Review of Finance, 18*(6), con el título "Once burned, twice shy?"; versión publicada no leída]

Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research, 11*, 2079–2107. https://www.jmlr.org/papers/v11/cawley10a.html

Center for Retirement Research at Boston College. (2009). *CRR 2009 Retirement Survey* [datos]. https://crr.bc.edu/crr-2009-retirement-survey-data/

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). https://doi.org/10.1145/2939672.2939785 [lectura parcial]

Chung, J., & Kim, B. (2022). *Dataset for Financial literacy and mutual fund investment behaviors: Evidence from South Korea during the financial crisis* [datos]. Mendeley Data. https://doi.org/10.17632/3mtsnpy3vt.2

Cohn, A., Engelmann, J., Fehr, E., & Maréchal, M. A. (2015). Evidence for countercyclical risk aversion: An experiment with financial professionals. *American Economic Review, 105*(2), 860–885. https://doi.org/10.1257/aer.20131314

Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., Van Calster, B., Ghassemi, M., Liu, X., Reitsma, J. B., et al. (2024). TRIPOD+AI statement: Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ, 385*, e078378. https://doi.org/10.1136/bmj-2023-078378

Elkan, C., & Noto, K. (2008). Learning classifiers from only positive and unlabeled data. En *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 213–220). https://doi.org/10.1145/1401890.1401920 [lectura parcial]

Elkind, D., Kaminski, K., Lo, A. W., Siah, K. W., & Wong, C. H. (2022). When do investors freak out? Machine learning predictions of panic selling. *The Journal of Financial Data Science, 4*(1), 11–39. https://doi.org/10.3905/jfds.2021.1.085 [leído el manuscrito de autor: https://hdl.handle.net/1721.1/141712]

FINRA Investor Education Foundation. (s. f.). *National Financial Capability Study: Data and downloads* [datos]. https://www.finrafoundation.org/knowledge-we-gain-share/nfcs/data-and-downloads

Fuentes Contreras, O., Salvo Cifuentes, E., & Hernández Fuentes, C. (2022). *Evolución y desempeño individual de los cambios de fondos en el Sistema de Pensiones* (Documento de Trabajo N.º 69). Superintendencia de Pensiones, Chile. https://repec.spensiones.cl/repec/3_doctrabajos/69_2022_cambios_de_fondos.pdf

Gächter, S., Johnson, E. J., & Herrmann, A. (2022). Individual-level loss aversion in riskless and risky choices. *Theory and Decision, 92*(3–4), 599–624. https://doi.org/10.1007/s11238-021-09839-8

Giglio, S., Maggiori, M., Stroebel, J., & Utkus, S. (2020). *Inside the mind of a stock market crash* (NBER Working Paper No. 27272). https://doi.org/10.3386/w27272 [publicado en 2021 en *PNAS, 118*(4), con otro título]

Gneezy, U., & Potters, J. (1997). An experiment on risk taking and evaluation periods. *The Quarterly Journal of Economics, 112*(2), 631–645. https://doi.org/10.1162/003355397555217

Göncü, A., Kuzubaş, T. U., & Saltoğlu, B. (2026). Machine learning for risk profiling: An analysis of pension fund participants. *Borsa Istanbul Review, 26*, 100800. https://doi.org/10.1016/j.bir.2026.100800

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems, 35*, 507–520. https://arxiv.org/abs/2207.08815

Guiso, L., Sapienza, P., & Zingales, L. (2018). Time varying risk aversion. *Journal of Financial Economics, 128*(3), 403–421. https://doi.org/10.1016/j.jfineco.2018.02.007 [leído en versión de trabajo NBER 19284]

Hoffmann, A. O. I., Post, T., & Pennings, J. M. E. (2013). Individual investor perceptions and behavior during the financial crisis. *Journal of Banking & Finance, 37*(1), 60–74. https://doi.org/10.1016/j.jbankfin.2012.08.007 [leído en versión de trabajo]

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns, 4*(9), 100804. https://doi.org/10.1016/j.patter.2023.100804

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems, 30*. [lectura parcial]

King, G., & Zeng, L. (2001). Logistic regression in rare events data. *Political Analysis, 9*(2), 137–163. https://doi.org/10.1093/oxfordjournals.pan.a004868 [lectura parcial]

Kozol, E. (2026). *Replication package for "Gender differences in behavioral biases among individual investors: Evidence from an emerging market"* [datos]. Zenodo. https://doi.org/10.5281/zenodo.20663153

Lal, S., Nguyen, T. X. T., Bawalle, A. A., Khan, M. S. R., & Kadoya, Y. (2024). Unraveling investor behavior: The role of hyperbolic discounting in panic selling behavior on the global COVID-19 financial crisis. *Behavioral Sciences, 14*(9), 795. https://doi.org/10.3390/bs14090795

Lejarraga, T., Ranganathan, K., & Wulff, D. U. (2024). Can simulated experience be harnessed to help people make investment decisions? *Judgment and Decision Making, 19*, e24. https://doi.org/10.1017/jdm.2024.17 [datos: https://osf.io/8vjna]

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*. [lectura parcial]

Lusardi, A., & Mitchell, O. S. (2014). The economic importance of financial literacy: Theory and evidence. *Journal of Economic Literature, 52*(1), 5–44. https://doi.org/10.1257/jel.52.1.5 [leído en versión de trabajo NBER 18952]

McDermott, M. B. A., Zhang, H., Hansen, L. H., Angelotti, G., & Gallifant, J. (2024). A closer look at AUROC and AUPRC under class imbalance. *38th Conference on Neural Information Processing Systems (NeurIPS 2024)*. https://arxiv.org/abs/2401.06091 [lectura parcial]

McElfresh, D., Khandagale, S., Valverde, J., Prasad C, V., Ramakrishnan, G., Goldblum, M., & White, C. (2023). When do neural nets outperform boosted trees on tabular data? *Advances in Neural Information Processing Systems, 36*, 76336–76369. https://arxiv.org/abs/2305.02997

Natarajan, N., Dhillon, I. S., Ravikumar, P., & Tewari, A. (2013). Learning with noisy labels. *Advances in Neural Information Processing Systems, 26*. [lectura parcial]

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems, 31*, 6639–6649. [lectura parcial]

Riley, R. D., Archer, L., Snell, K. I. E., Ensor, J., Dhiman, P., Martin, G. P., Bonnett, L. J., & Collins, G. S. (2024). Evaluation of clinical prediction models (part 2): How to undertake an external validation study. *BMJ, 384*, e074820. https://doi.org/10.1136/bmj-2023-074820

Riley, R. D., Snell, K. I. E., Ensor, J., Burke, D. L., Harrell, F. E., Jr., Moons, K. G. M., & Collins, G. S. (2019). Minimum sample size for developing a multivariable prediction model: PART II – binary and time-to-event outcomes. *Statistics in Medicine, 38*(7), 1276–1296. https://doi.org/10.1002/sim.7992

Sanz-Cruzado, J., Droukas, N., & McCreadie, R. (2024). *FAR-Trans: An investment dataset for financial asset recommendation*. IJCAI-2024 Workshop on Recommender Systems in Finance. https://arxiv.org/abs/2407.08692 [datos: https://researchdata.gla.ac.uk/1658/]

Schwaiger, R., Strucks, M., & Zeisberger, S. (2026). The consequences of narrow framing for risk taking: A stress test of myopic loss aversion. *Management Science, 72*(2), 1324–1340. https://doi.org/10.1287/mnsc.2024.05720 [datos: https://osf.io/9xmda]

Shwartz-Ziv, R., & Armon, A. (2022). Tabular data: Deep learning is not all you need. *Information Fusion, 81*, 84–90. https://doi.org/10.1016/j.inffus.2021.11.011

Storkey, A. (2009). When training and test sets are different: Characterizing learning transfer. En J. Quiñonero-Candela, M. Sugiyama, A. Schwaighofer & N. D. Lawrence (Eds.), *Dataset shift in machine learning* (pp. 3–28). MIT Press. https://doi.org/10.7551/mitpress/7921.003.0004 [lectura parcial]

Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., & Steyerberg, E. W. (2019). Calibration: The Achilles heel of predictive analytics. *BMC Medicine, 17*, 230. https://doi.org/10.1186/s12916-019-1466-7

van den Goorbergh, R., van Smeden, M., Timmerman, D., & Van Calster, B. (2022). The harm of class imbalance corrections for risk prediction models: Illustration and simulation using logistic regression. *Journal of the American Medical Informatics Association, 29*(9), 1525–1534. https://doi.org/10.1093/jamia/ocac093

van Smeden, M., Moons, K. G. M., de Groot, J. A. H., Collins, G. S., Altman, D. G., Eijkemans, M. J. C., & Reitsma, J. B. (2019). Sample size for binary logistic prediction models: Beyond events per variable criteria. *Statistical Methods in Medical Research, 28*(8), 2455–2474. https://doi.org/10.1177/0962280218784726

Varma, S., & Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics, 7*, 91. https://doi.org/10.1186/1471-2105-7-91

Vickers, A. J., van Calster, B., & Steyerberg, E. W. (2019). A simple, step-by-step guide to interpreting decision curve analysis. *Diagnostic and Prognostic Research, 3*, 18. https://doi.org/10.1186/s41512-019-0064-7 [lectura parcial]

Vuong, Q.-H., Nguyen, P.-T., Jin, R., Hoang, G., La, V.-P., & Nguyen, M.-H. (2025). *Fear and fear regulation of Chinese and Vietnamese investors in the extremely volatile markets* [datos]. Zenodo. https://doi.org/10.5281/zenodo.14868729

Weber, M., Weber, E. U., & Nosić, A. (2013). Who takes risks when and why: Determinants of changes in investor risk taking. *Review of Finance, 17*(3), 847–883. https://doi.org/10.1093/rof/rfs024

Wieczorek, J., Guerin, C., & McMahon, T. (2022). K-fold cross-validation for complex sample surveys. *Stat, 11*(1), e454. https://doi.org/10.1002/sta4.454

Wohlfart, J., Weber, A., & Hanspal, T. (2020). *Replication data for: Exposure to the COVID-19 stock market crash and its effect on household expectations* [datos]. Harvard Dataverse. https://doi.org/10.7910/DVN/XP63F9