Pontificia Universidad Javeriana · Especialización en Inteligencia Artificial

Proyecto de Aplicación en IA · Módulo 2: Prototipado

BolsaLAB

Ciclo 3A: prototipado del modelo (sprint 5)

Grupo 10

Jenny Paola Castellanos

Luis Guillermo Yépez

Dilan Vega

Juan Gilberto Ayala

26 de octubre de 2026

1. Tarea, Identificar los criterios de "calidad" del modelo:

Para el desarrollo del proyecto **BolsaLAB**, se seleccionó como base principal de entrenamiento la encuesta japonesa sobre la caída de mercado de marzo de 2020 (Bawalle et al., 2025), la cual comprende un total de 54.704 datos, y adicionalmente, con el propósito de evaluar el desempeño del modelo fuera del contexto japonés, se incorporaron diversos datasets internacionales de contraste, destacando el panel SCF 2007-2009 de Estados Unidos, la encuesta desarrollada por Hanspal et al. (2020), la NFCS Investor Survey 2018 de FINRA, la CRR 2009 Retirement Survey.

Por otro lado, se analizó la pertinencia de utilizar el conjunto de datos de Rentabilidades de los Fondos de Inversión Colectiva (FIC), provisto por la Superintendencia Financiera en Colombia. Sin embargo, tras la evaluación, se determinó que no es apto para realizar entrenamientos o contrastes directos, debido a que carece de registros detallados a nivel individual que permitan rastrear la conducta de retirarse de una inversión a nivel de persona. En consecuencia, este conjunto de datos se conserva exclusivamente para propósitos de contexto general dentro del proyecto.

1.1. Limpieza de datos:

Para llevar a cabo la limpieza de datos, se implementó el script de BolsaLAB, el cual procesa el archivo original y filtra únicamente a los encuestados que poseían inversiones, clasificándolos entre quienes vendieron todo, vendieron parte o mantuvieron sus posiciones. Así es que se excluye a quienes no tenían inversiones, ya que carecían de activos para liquidar y su inclusión habría enseñado al modelo a separar inversionistas de no inversionistas en lugar de predecir la conducta de venta. Como resultado de este filtro, la población de entrenamiento quedó conformada por 54.704 inversionistas activos, de los cuales un 19,87 % vendió todo o parte durante la crisis, a partir de un universo inicial de 191.762 encuestados.

Asimismo, antes de iniciar el entrenamiento, se fijaron valores esperados estrictos que son contrastados mediante pruebas automáticas cada vez que se ejecuta el código. Dado que ningún registro superó los límites de las escalas establecidas, no fue necesario eliminar ni corregir datos de manera arbitraria, conservando incluso a aquellos usuarios que repitieron respuestas idénticas debido a la naturaleza de las preguntas cerradas. Este protocolo de calidad que se realiza, busca garantizar la integridad, consistencia y reproducibilidad de la base de datos procesada para las siguientes fases del proyecto.

1.2. Construcción de datos.

En el proceso de construcción de variables, se definió como variable objetivo la venta (sold) asignando un valor de 1 si la persona vendió todo o parte durante la caída, y 0 si mantuvo sus posiciones.

De igual forma se estructuraron 17 variables de entrada explicativas alineadas con los cuestionarios, entre las cuales se destacan las tres preguntas de conocimiento financiero ingresadas por separado, también la confianza y el exceso de confianza. Se toman variables demográficas como la edad y su término cuadrático para captar la forma en U de las ventas, el nivel educativo, el estado civil, la presencia de hijos y los rangos de ingreso y activos del hogar.

Por otra parte, se llevó a cabo una auditoría y prevención de fugas de información (*data leakage*), excluyendo columnas que revelaran el resultado final o duplican información como agregados de conocimiento o variables de pánico previo. Además, se avanzó en la integración y formateo de los

datos, unificando las dimensiones en una estructura tabular por persona almacenada, e identificando las 5 variables demográficas comunes para el contraste con el panel SCF de Estados Unidos. Todo este flujo fue estandarizado en nombres e idioma inglés, respaldado por un conjunto de 23 pruebas automáticas que garantizan la reproducibilidad del pipeline.

Se realizó una auditoría para excluir columnas que contenían información directa sobre el resultado o redundancias analíticas, como Tot_Panic_Sell, puntajes globales de alfabetización que agrupan las preguntas o variables transformadas en logaritmo, lo anterior buscando mediante pruebas automáticas que ningún dato de conducta futura contaminaría el entrenamiento.

1.3. Integración de datos

Se unificaron los datos, en una estructura tabular individualizada por persona, donde las dimensiones cognitivas, demográficas y financieras se obtienen a partir de la fuente de entrenamiento principal. De igual forma para llevar a cabo el contraste internacional con el panel SCF de Estados Unidos, se articularon ambas fuentes mediante la identificación y alineación de cinco variables demográficas clave que se encontraban disponibles de manera común en ambos instrumentos de medición.

Se estandarizaron los nombres de las columnas en idioma inglés y formato minúscula para mantener la compatibilidad con el ecosistema de desarrollo.

Los datos limpios e intermedios se almacenaron, asegurando la reproducibilidad del pipeline mediante un total de 23 pruebas automáticas distribuidas en las etapas de limpieza, variables y panel de contraste.

Criterios de calidad relacionados con nuestro producto

Tabla 1. Criterios del producto.

Criterio	Por qué
La app muestra si la persona es más, igual o menos propensa a vender que el promedio, **nunca un porcentaje**	El modelo aprendió de japoneses y lo usaremos en personas de Colombia. Al cambiar de población, la calibración es lo primero que falla (Van Calster et al., 2019; Riley et al., 2024)
Explica el resultado con las respuestas que más pesaron	La persona debe entender por qué, y saber qué puede aprender
Separa «lo que puedes trabajar» (finanzas y confianza) de «tu situación» (edad, sexo, ingreso)	Para que el resultado lleve a una acción y no culpe a nadie por lo que no depende de él
No recomienda comprar ni vender activos	BolsaLAB educa; no es asesoría de inversión
Avisa cuando la persona queda fuera de lo que vio el modelo (por ejemplo, una edad fuera de 18 a 93)	Fuera de ese rango el modelo no tiene en qué basarse

Fuente: elaboración propia.

Tarea 2- Establecer los conjuntos de datos de entrenamiento, test y validación

En el ciclo 2 dejamos lista la tabla para entrenar: 54.704 inversionistas japoneses de la encuesta de Bawalle, Khan y Kadoya (2025) sobre la caída de marzo de 2020, con 17 variables (una por pregunta de

la app) y una columna que dice si vendieron o mantuvieron. También dejamos escritas las reglas para entrenar y medir los modelos. En este ciclo las aplicamos:

https://github.com/EspecializacionIA1/bolsalab/blob/main/docs/protocolo-evaluacion.md

2.1 Cambio frente al plan del Módulo 1

En el Módulo 1 íbamos a clasificar perfiles de riesgo, pero en el estado del arte del ciclo 2 vimos que no hay datos abiertos de colombianos para eso. Sí hay datos reales para otra pregunta: ¿quién vende cuando la bolsa cae? Así que el modelo ahora predice si una persona vende o mantiene, y lo medimos con el AUROC, que funciona bien aunque solo el 20 % haya vendido y nos deja compararnos con Elkind et al. (2022). Las tareas del sprint son las mismas del plan.

2.2 Partición 80/20

Antes de entrenar, guardamos el 20 % de las personas para la prueba final, con la misma proporción de ventas y la semilla 42 para que todos usemos las mismas personas. Nadie la mira mientras elegimos el modelo. Solo la usamos una vez, con el modelo final, en el ciclo 4.

Tabla 2. Partición de la encuesta japonesa.

Conjunto	Personas	Vendieron	Proporción
Entrenamiento (80 %)	43.763	8.695	19,87 %
Prueba final (20 %)	10.941	2.174	19,87 %
Total	54.704	10.869	19,87 %

Fuente: elaboración propia.

Código: función split_data en bolsalab/modeling/train.py. Regla: sección 4 de docs/protocolo-evaluacion.md.

2.3 Validación cruzada anidada 5 × 3

Con el 80 % usamos validación anidada. Dividimos los datos en 5 partes: el modelo aprende con 4 y lo medimos con la que sobra, y repetimos hasta que cada parte sirve una vez para medir. Dentro de las 4 partes de aprendizaje hacemos otra división en 3 para elegir los ajustes del modelo (por ejemplo, qué tan profundo es cada árbol). Así, los datos con que medimos nunca se usan para elegir, y el resultado no sale mejor de lo que es (Varma y Simon, 2006; Cawley y Talbot, 2010).

- Todos los modelos usan las mismas 5 partes, para que compitan en igualdad.
- El escalado se calcula solo con los datos de aprendizaje. Escalar es poner las variables en una medida parecida (la edad va de 18 a 94 y las preguntas de 0 a 1). Si se calcula con todos los datos, el modelo ve sin querer algo de los datos de prueba (Kapoor y Narayanan, 2023).
- No "emparejamos" las clases. Solo el 20 % vendió. Hay técnicas para que el modelo vea más casos de venta: SMOTE inventa personas parecidas a las que vendieron, y los pesos por clase hacen que cada venta cuente más. No las usamos porque, según van den Goorbergh et al. (2022), no mejoran el AUROC y hacen que el modelo exagere la probabilidad de vender.

2.4 Prueba externa en EE. UU. con la NFCS 2018

La NFCS es una encuesta de Estados Unidos que les preguntó a inversionistas qué hicieron en la caída de febrero de 2018, con las mismas tres preguntas de finanzas que usa Japón. La usamos para probar si el modelo funciona fuera de Japón.

Tabla 3. La NFCS 2018 frente a la encuesta japonesa.

	Japón (entrenamiento)	NFCS 2018 (EE. UU.)
Caída	Marzo de 2020 (COVID-19)	Febrero de 2018 (cerca de 10 %)
Inversionistas	54.704	1.825
Vendieron	19,9 %	4,6 % (84 personas)
Variables	17	15 de 17 (no existen urban ni short_term_view)
Exceso de confianza	7,5 %	48 %

Fuente: elaboración propia.

Pusimos cada variable de la NFCS con el mismo nombre y escala que en Japón; por ejemplo, la confianza pasa de una escala de 1 a 7 a una de 1 a 5. 17 pruebas automáticas revisan la conversión. Por las reglas de FINRA, los datos no se comparten: cada integrante descarga su copia.

2.5 Límite temporal de los datos de Japón

La encuesta japonesa se hizo a finales de 2023 y preguntó qué hicieron las personas en marzo de 2020 (Bawalle et al., 2025). O sea, el conocimiento, la confianza y la aversión al riesgo se midieron después de la venta, y la experiencia pudo cambiar esas respuestas. No se puede corregir con los datos, así que lo declaramos como límite.

3.1 tres modelos, de más simple a más complejo

Cada modelo se escogió de acuerdo a los resultados arrojados por el estado del arte y la rejilla de hiperparametros se adecuo de acuerdo cada experimento :

Tabla 7. Modelos seleccionados.

Modelo	Responsable	Por qué entra
Modelo	**Rangos**	**Combinaciones**
XGBoost	`learning_rate` 0,01; 0,03 o 0,1; `max_depth` 3, 5 o 7; `subsample` 0,8 o 1,0; `min_child_weight` 1 o 10	36
LightGBM	`learning_rate` 0,01; 0,03 o 0,1; `max_depth` 3, 5 o 7; `num_leaves`	36

	15 o 31; `min_child_samples` 20 o 100	
CatBoost	`learning_rate` 0,01; 0,03 o 0,1; `depth` 4, 6 u 8; `l2_leaf_reg` 1, 3 o 10	27

XGBoost. CatBoost tuvo el AUROC más alto (0,661), pero XGBoost y LightGBM quedaron a menos de una desviación estándar. Con la regla del protocolo, entre modelos empatados gana el que aparece primero en el orden de la Tabla 7. Ese orden pone a XGBoost antes que a LightGBM y CatBoost.

Todos los modelos superan al trivial, pero por poco: el mejor AUROC queda unos 0,16 por encima del azar. Este valor está lejos del umbral de alarma de 0,82, así que no hay indicios de fuga.

Tabla 8. Rangos de variables y cambios (feature engineering).

Versión	Cambios
Base	Sin cambios
Sin edad al cuadrado	Se quita `age_squared`
Logaritmo del ingreso	Se aplica logaritmo a `income_bracket`
Edad por ingreso	Se agrega la interacción `age` × `income_bracket`
Base	Sin cambios

Fuente: elaboración propia.

3.2 Regla para elegir el ganador

La fijamos el 14 de octubre, antes de entrenar: **gana el de mayor AUROC medio, salvo que uno más simple quede a menos de una desviación estándar; entonces gana el simple.** Si siguen empatados, decide la pendiente de calibración más cercana a 1. McElfresh et al. (2023) encuentran diferencias pequeñas entre familias en datos tabulares, y un modelo simple se le explica mejor al usuario. El umbral de una desviación y el desempate son decisión nuestra.

- **Orden de simplicidad.** Un modelo es más simple que otro si aparece antes en la Tabla 7: XGBoost, LightGBM, CatBoost . Entre los tres modelos de boosting no hay una diferencia real de complejidad, así que su orden es una convención: XGBoost, luego LightGBM y luego CatBoost.
- **Desviación de referencia.** Se usa la desviación estándar del AUROC del mejor modelo en las 5 particiones externas. Cuentan como empatados los modelos cuyo AUROC medio no queda más de una desviación por debajo de ese mejor modelo.
- **Reemplazo en los experimentos.** Antes de correr los 24 experimentos fijamos esta condición: un experimento reemplaza a XGBoost solo si supera su AUROC más una desviación, es decir,

0,6636. Así, una mejora del tamaño del ruido entre particiones no basta para cambiar de modelo. El mejor experimento llegó a 0,6613, así que XGBoost sigue siendo el ganador.

3.3 Exploración adicional

- Antes de correrla, el 21 de octubre, registramos una exploración más amplia: rangos ampliados para XGBoost, LightGBM y CatBoost (más tasas de aprendizaje, profundidades y regularización) y cuatro versiones de las variables (sin cambios, sin edad al cuadrado, con logaritmo del ingreso y con edad por ingreso). Son 24 experimentos. Un experimento reemplaza al ganador solo si su AUROC lo supera por más de una desviación estándar.
- Medir a XGBoost una sola vez en el 20 % de prueba. Reportar el AUROC con intervalo de confianza del 95 % (1.000 remuestreos), el AUPRC, la calibración, el Brier con beneficio neto y las ventas en el 10 % de mayor riesgo.
- Explicar sus predicciones con SHAP y revisar que ninguna variable domine la explicación, que es una de las alarmas de fuga.
- Probarlo en EE. UU. con la NFCS para ver cómo se comporta al cambiar de población.

Tarea 4- Aplicar el modelo de validación diseñado en el paso anterior

4.1 Comparación de los siete modelos

Tabla 9. Resultados de la validación anidada 5 × 3 (media de las 5 particiones externas).

Modelo	AUROC	AUPRC	Brier	Intercepto	Pendiente
Trivial	0,500	0,199	0,159	−0,47	0,66
Regresión logística	0,646 ± 0,002	0,305	0,152	0,00	1,00
Random Forest	0,657 ± 0,004	0,330	0,151	0,30	1,23
XGBoost	**0,660 ± 0,004**	**0,331**	**0,150**	**0,07**	**1,06**
LightGBM	0,660 ± 0,004	0,331	0,150	0,07	1,05
CatBoost	0,661 ± 0,004	0,332	0,150	0,13	1,10
Red neuronal	0,635 ± 0,018	0,303	0,153	−0,28	0,82

Fuente: elaboración propia.

Gana XGBoost. CatBoost sacó 0,661, pero la diferencia con XGBoost (0,001) es menor que una desviación (0,004), y por la regla gana el más simple de la lista. Además, XGBoost calibra mejor: pendiente 1,06 frente a 1,10. La validación eligió learning_rate 0,03 y profundidad 3.

Qué dice esto de nuestras hipótesis:

- **H3 se cumple.** Un modelo solo con respuestas de cuestionario se distingue mejor que el azar (0,660 frente a 0,500), pero bastante peor que uno con historial de portafolio (0,821 en Elkind et al., 2022).

- **H4 no se cumple.** Esperábamos que los árboles no superaran a la logística por más que la variación, pero XGBoost la supera por 0,014, unas cuatro desviaciones. La diferencia es real, aunque pequeña.
- La red neuronal queda de última y es la más inestable (± 0,018), como anticipan Grinsztajn para datos tabulares.

4.2 Resultados de la exploración adicional

XGBoost sigue siendo el ganador. Para reemplazarlo había que pasar de 0,6636 (su AUROC más una desviación) y el mejor experimento llegó a 0,6613.

- **Ajustar más no lo mejora.** Los 24 experimentos quedaron entre 0,659 y 0,661. El límite está en la información del cuestionario, no en el modelo, lo que concuerda con el pseudo R^2 menor de 0,04 que reportan Bawalle et al. (2025).
- **Las transformaciones no cambian nada en los árboles.** Quitar la edad al cuadrado o usar el logaritmo del ingreso da el mismo resultado, porque los árboles cortan por mayor o menor que y esas transformaciones no cambian el orden de las personas.
- **Los ajustes son estables.** En XGBoost y LightGBM las 5 particiones eligieron los mismos hiperparámetros, y todos los modelos eligieron la profundidad más baja disponible. Los datos piden modelos simples.

4.3 Explicación de nuestro modelo ganador con SHAP

Con shap.TreeExplainer calculamos cuánto pesa cada respuesta en 5.000 personas del entrenamiento. SHAP explica lo que hace el modelo, no la causa de la venta.



Figura 1. Peso medio de cada respuesta en la predicción (|SHAP|). Fuente: elaboración propia.

Tabla 10. Respuestas que más pesan.

Respuesta	Parte del peso total	Dirección
Sexo (hombre)	28 %	Los hombres venden más

Acierta diversificación	15 %	Acertar baja la venta
Confianza en lo que sabe	9 %	Más confianza sube la venta
Acierta inflación	7 %	Acertar baja la venta
Edad	7 %	Sube en las edades altas
Aversión al riesgo y visión de corto plazo	13 % entre las dos	La app todavía no las pregunta
Acierta interés compuesto	5 %	Acertar baja la venta

Fuente: elaboración propia.

- **Las tres preguntas de finanzas suman el 27 % y siempre bajan la venta.** Va en la dirección de la hipótesis H1 y de Bawalle et al. (2025). Es la parte que la app puede enseñar.
- **El sexo es lo que más pesa.** En el entrenamiento vendió el 23,6 % de los hombres y el 12,2 % de las mujeres, así que no es un error del modelo. Es el resultado que más cuidamos al mostrarlo (sección 6.4).
- **El exceso de confianza casi no pesa (1 %), aunque quienes lo tienen vendieron más** (28,4 % frente a 19,2 %). Se construye con la confianza y las preguntas de finanzas, y SHAP le da su peso a esas dos. Es la advertencia conocida de SHAP con variables relacionadas.
- **Ninguna variable domina sola**, así que no se activa la alarma de fuga.

4.4 Desempeño por grupos

Revisamos si el modelo funciona peor para algún grupo, con las predicciones de validación cruzada del entrenamiento. Cortamos la edad entre 40 y 60 años y el ingreso en los tramos 4 y 7 para tener grupos grandes; es decisión nuestra.

Tabla 11. AUROC y calibración por grupo.

Grupo	Personas	Vendió	Predicción media	AUROC	Pendiente
Hombres	29.348	23,6 %	23,5 %	0,623	1,06
Mujeres	14.415	12,2 %	12,5 %	0,643	1,06
18 a 39 años	13.449	18,3 %	18,2 %	0,693	1,13
40 a 59 años	22.635	18,9 %	19,0 %	0,646	1,04
60 años o más	7.679	25,6 %	25,3 %	**0,588**	**0,85**
Ingreso, tramos 1 a 4	18.045	22,2 %	22,0 %	0,660	1,02
Ingreso, tramos 5 a 7	20.103	17,9 %	18,2 %	0,653	1,07
Ingreso, tramos 8 o más	5.615	19,5 %	19,0 %	0,652	1,14

Fuente: elaboración propia.

- **En promedio, el modelo acierta en todos los grupos:** la predicción media queda a menos de medio punto de lo que pasó.
- **Con los mayores de 60 distingue peor,** (0,588 frente a 0,693 en los de 18 a 39), y su pendiente de 0,85 dice que ahí las probabilidades salen algo exageradas. Es el grupo que más vendió. En la app, el resultado para esta edad debe leerse con más cautela.
- **Dentro de cada sexo el AUROC baja,** (0,62 y 0,64 frente a 0,66 en total) porque parte de lo que distingue el modelo es el sexo mismo. No hay un sexo para el que funcione claramente peor.

Prototipo: nuestro modelo conectado a una persona

Para el prototipo entrenamos nuestro modelo ganador únicamente con el 80 % destinado al entrenamiento y con los ajustes elegidos durante la validación. No usamos el conjunto de prueba final para entrenarlo ni para tomar decisiones. El modelo queda guardado en models/crash_reaction_v1 junto con los cortes de las categorías.

Tabla 12. Piezas del prototipo.

Pieza	Qué hace	Estado
Predicción para una persona (predict.py)	De las 14 respuestas del cuestionario a las 17 variables, la categoría, las respuestas que más pesaron y avisos si la persona queda fuera del rango de entrenamiento	Lista, con 8 pruebas automáticas
App en Streamlit (app/app.py)	Cuestionario; resultado con su explicación y qué aprender según la pregunta que falló; cómo funciona el modelo (SHAP global, métricas y límites)	En desarrollo; corre en el computador
Textos de las explicaciones	Qué significa cada factor y qué aprender, en español sencillo	Pasa al ciclo 3B
Prueba con usuarios	Perfiles ambiguos y si entienden la explicación, con consentimiento según la Ley 1581 de 2012	Pasa al ciclo 3B

Fuente: elaboración propia.

Dos decisiones del prototipo: la app todavía no pregunta la aversión al riesgo ni la visión de corto plazo, porque no conocemos la redacción japonesa; usa el valor más común (0,5 y 2), lo dice en pantalla y no las muestra como factor. El ingreso y los ahorros se preguntan en cinco niveles frente a la gente del país y se llevan al tramo japonés en la misma posición, de forma provisional hasta tener los tramos colombianos.

Límites de nuestro proyecto

- Nuestro modelo se entrenó con datos de inversionistas japoneses, aunque el público previsto de BolsaLAB está en Colombia. Como no contamos con datos individuales abiertos de Colombia para este objetivo, la app mostrará categorías y no probabilidades personales. La validación con la NFCS nos permitirá estudiar cómo cambia el desempeño al pasar a otra población
- Las respuestas se dieron después de la caída (sección 2.5).
- El modelo explica poco de la venta. Un AUROC de 0,66 sirve para ordenar y enseñar, no para decidir por nadie.
- SHAP toma la variable de sexo masculo porque según los datos los hombres vendieron mas, pero no significa que ser hombre sea causal de venta.
- Se determinó como protocolo antes de ver los resultados las reglas que fueron elegidas nosotros mismos como grupo: 20% de la prueba, los 5 y 3 partes, la semilla 42, el umbral de una desviación y los tercios.

Aprendizajes y próximos pasos

Aprendizajes

- Fijar las reglas antes de entrenar evita reprocesos: cuando CatBoost quedó una milésima arriba, confirma la regla inicial.
- La herramienta SHAP no solo explica, también sirve como guía analítica donde reveló las variables que se deben revisar con mayor detenimiento como lo son el género o las preguntas de conocimiento financiero, las cuales se deben reforzar.

Próximos pasos (ciclo 3B y ciclo 4)

- En el ciclo 3B completaremos en el protocolo la regla para las dos variables que faltan en la NFCS y ejecutaremos una sola vez la prueba Japón → EE. UU., con nuestro modelo congelado.
- Terminaremos los textos de la app y probaremos el prototipo con usuarios.
- En el ciclo 4 evaluaremos nuestro modelo ganador con el 20 % de prueba reservado y lo haremos una sola vez.

Referencias

Assel, M., Sjoberg, D. D., & Vickers, A. J. (2017). The Brier score does not evaluate the clinical utility of diagnostic tests or prediction models. Diagnostic and Prognostic Research, 1, 19.

Bawalle, A. A., Khan, M. S. R., & Kadoya, Y. (2025). Overconfidence, financial literacy, and panic selling: Evidence from Japan. PLOS ONE, 20(3), e0315622. https://doi.org/10.1371/journal.pone.0315622

Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. Journal of Machine Learning Research, 11, 2079–2107.

Elkind, D., Kaminski, K., Lo, A. W., Siah, K. W., & Wong, C. H. (2022). When do investors freak out? Machine learning predictions of panic selling. The Journal of Financial Data Science, 4(1), 11–39.

FINRA Investor Education Foundation. National Financial Capability Study, Investor Survey 2018 [datos]. https://www.finrafoundation.org/knowledge-we-gain-share/nfcs/data-and-downloads

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? NeurIPS 35.

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. Patterns, 4(9), 100804.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. NeurIPS 30.

McDermott, M. B. A., et al. (2024). A closer look at AUROC and AUPRC under class imbalance. NeurIPS 2024.

McElfresh, D., et al. (2023). When do neural nets outperform boosted trees on tabular data? NeurIPS 36.

Riley, R. D., et al. (2024). Evaluation of clinical prediction models (part 2): How to undertake an external validation study. BMJ, 384, e074820.

Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., & Steyerberg, E. W. (2019). Calibration: The Achilles heel of predictive analytics. BMC Medicine, 17, 230.

van den Goorbergh, R., van Smeden, M., Timmerman, D., & Van Calster, B. (2022). The harm of class imbalance corrections for risk prediction models. JAMIA, 29(9), 1525–1534.

van Smeden, M., et al. (2019). Sample size for binary logistic prediction models: Beyond events per variable criteria. Statistical Methods in Medical Research, 28(8), 2455–2474.

Varma, S., & Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. BMC Bioinformatics, 7, 91.

Vickers, A. J., van Calster, B., & Steyerberg, E. W. (2019). A simple, step-by-step guide to interpreting decision curve analysis. Diagnostic and Prognostic Research, 3, 18.

Anexos

Archivo que acompaña esta entrega: Grupo-10 - Backlog Ciclo 3A (actividades, responsables, herramientas de Design Thinking y entregables).

Repositorio del proyecto: https://github.com/EspecializacionIA1/bolsalab.

Tabla 13. Dónde está cada resultado en el repositorio.

Resultado	Archivo
Reglas de evaluación	docs/protocolo-evaluacion.md
Partición, validación y comparación	bolsalab/modeling/train.py; reports/benchmark.csv
Exploración adicional	bolsalab/modeling/experiments.py; docs/experimentos.md; reports/experiments.csv
SHAP	bolsalab/explain.py; reports/shap_global.csv; notebook «Explicación del modelo con SHAP»
Desempeño por grupos	bolsalab/modeling/groups.py; reports/groups.csv
NFCS	bolsalab/nfcs.py; docs/nfcs.md; notebook «NFCS frente a Japón»
Prototipo	bolsalab/modeling/predict.py; app/app.py; docs/prototipo.md

Fuente: elaboración propia.